

REPORT 4**Documento de Projeto****IDENTIFICAÇÃO**

Nº	NOME	e-mail	Telefone
210058	Andressa Braga Vieira Rodrigues	andressabragavr@gmail.com	(15) 99855-5855
211202	Diogo Vital Vieira	diogovitalvieira@gmail.com	(15) 99159-5967
210331	Pedro Henrique Lisboa	plisboa2003@gmail.com	(15) 98108-6208

TÍTULO:

Gerenciador de Certificados Acadêmicos com Leitura Automática de Documentos

LÍDER DO GRUPO:

Diogo Vital Vieira

ORIENTADOR:

Andreia Damásio de Leles

Data da Entrega: 22/05/2025

Visto do Orientador

SUMÁRIO

1	INTRODUÇÃO DO TRABALHO.....	2
2	TRABALHOS CORRELATOS.....	5
3	O QUE SERÁ FEITO.....	7
4	O QUE NÃO SERÁ FEITO.....	10
5	BENEFÍCIOS.....	11
6	METAS PARA O TCC 2.....	12
7	RECURSOS UTILIZADOS.....	13
	REFERÊNCIAS.....	14

1 INTRODUÇÃO DO TRABALHO

Um dos pilares fundamentais na formação acadêmica dos estudantes das instituições de ensino superior é o cumprimento das horas complementares, atividades como: iniciações científicas, participação em eventos técnico-científicos, programas de monitorias e tutoria e publicações científicas, desenvolvidas na própria ou em outras instituições. Tais atividades, segundo o Ministério da Educação (MEC), consistem em práticas acadêmicas que ampliam e aprofundam a formação dos alunos, contribuindo diretamente para o aprimoramento dos conhecimentos adquiridos ao longo do curso (BRASIL, 2016).

A comprovação dessas práticas varia de acordo com as normas de cada instituição, podendo ser obrigatória uma certificação que ateste o cumprimento das tarefas realizadas e a respectiva carga horária (Faculdade Fasouza, 2024). Tais experiências são obrigatórias para todos os estudantes de cursos superiores, correspondendo a aproximadamente 20% da carga horária total das graduações (Frauches, 2012). Desse modo, os certificados acadêmicos tornam-se documentos essenciais e imprescindíveis na validação dessas práticas complementares e na formação integral do estudante.

Atualmente, na maioria das instituições de ensino superior, o processo de validação desses documentos é realizado predominantemente de maneira manual, exigindo o preenchimento de formulários pelos estudantes ou simplesmente o envio dos certificados diretamente à coordenação do curso, sendo em ambos os casos necessária a validação pelo coordenador responsável (Universidade Federal de Santa Catarina, 2022). Procedimentos manuais no âmbito acadêmico apresentam diversos desafios significativos na vida acadêmica, tais como lentidão no processamento das informações, atrasos na aprovação das práticas realizadas e uma elevada incidência de erros humanos (Eadsimples, 2023; Nissen, 2022).

De acordo com Brito (2024) e Bezerra *et al.* (2024), a ausência de um sistema automatizado nas universidades compromete diretamente a eficiência e a precisão dos processos acadêmicos. A ausência desses processos, podem ocasionar uma duplicidade em documentos, ou até mesmo uma validação

errônea acerca das horas atribuídas nas atividades extracurriculares, dificultando assim o controle e a eficiência das informações acadêmicas.

Perante tais constatações, o presente trabalho tem como objetivo geral, o desenvolvimento de um sistema web, onde os estudantes poderão fazer o *upload* de documentos para que seja feita de forma automática a extração e a categorização das informações contidas em certificados acadêmicos (Bernadoni, 2023). Além disso, o sistema também contará com um painel administrativo para coordenadores, permitindo o acompanhamento e validação dos certificados, bem como um sistema de notificações para informar alunos e coordenação sobre o status das validações. Assim, possivelmente haverá otimização e facilitação do monitoramento e controle por parte das coordenações, promovendo maior transparência e segurança nesse processo.

Para alcançar a solução proposta, serão aplicadas tecnologias adotadas no mercado, como o *Optical Character Recognition* (OCR) (Amutha e Prashath, 2024) para o processo de extração de dados, a categorização automatizada por meio de *Large Language Models* (LLMs) (Xiao e Zhu, 2025; Nishio *et al.*, 2024), além da técnica de *Retrieval-Augmented Generation* (RAG) para enriquecer as respostas do LLM com base em dados relevantes recuperados dinamicamente (Gao *et al.*, 2023). Para o desenvolvimento do *backend* será utilizado TypeScript, para o *frontend*, Vue.js e o banco de dados, MongoDB. Este sistema será denominado pelo nome fantasia de *DocVerifier*.

Diante do apresentado, torna-se evidente a necessidade da modernização dentro das técnicas utilizadas atualmente, observando que, a conferência manual dos dados ocasiona uma sobrecarga aos supervisores pedagógicos responsáveis por tais atividades, como também influenciam na confiabilidade dos estudantes perante o tempo de retorno da aprovação da documentação (Universidade Potiguar, 2023). Assim, a automação desse fluxo torna-se fundamental para a eficiência e segurança dos processos acadêmicos.

Dessa forma, a metodologia abordada consiste, inicialmente, na coleta de dados que comprovem a necessidade da automatização de processos acadêmicos. Tal pesquisa será realizada por meio de entrevistas e questionários estruturados a estudantes e coordenadores de cursos para identificar dificuldades e necessidades dentro do processo atual (Cooper e Reiman, 2003;

Garrett, 2010). Com base nas informações levantadas, os requisitos serão especificados para desenvolvimento do sistema *DocVerifier*.

Após a implementação do sistema, será realizada uma nova fase de testes com o mesmo grupo da primeira etapa para avaliar a eficiência e eficácia da ferramenta em comparação ao processo manual atual. Os resultados serão analisados e medidos por meio de taxa de certificados validados por tempo, taxa de repetição de documentos por ID, taxa de aprovação pelo público-alvo e satisfação dos *stakeholders*, com o objetivo de demonstrar que a automação do processo é eficiente e eficaz.

Para garantir a confiabilidade dos modelos de OCR e LLM utilizados no sistema, serão realizados testes com diferentes LLMs de fabricantes como Google, Meta e OpenAI, com foco na precisão na análise dos certificados. Os resultados gerados pelos *prompts* serão avaliados por coordenadores de curso, com base nos critérios já adotados na validação manual. Essa validação é essencial para a RAG, pois sua eficácia depende da capacidade da LLM em interpretar corretamente os textos e utilizar as informações recuperadas. A partir dessas avaliações, serão definidas métricas específicas para comparar o desempenho entre os modelos e validar sua aplicabilidade no contexto acadêmico.

2 TRABALHOS CORRELATOS

Diversas iniciativas, tanto no meio acadêmico quanto no mercado, têm se intensificado nos últimos anos devido à crescente demanda por soluções que automatizem processos em diferentes áreas, incluindo o ambiente educacional. No contexto das instituições de ensino superior, isso tem se refletido na busca por ferramentas que otimizem o tratamento de documentos acadêmicos, cuja validação ainda depende, em muitos casos, de processos manuais.

Dentre os trabalhos desenvolvidos em instituições brasileiras, destaca-se o de Alves (2022), da Universidade Federal de Santa Catarina, que propôs a utilização de OCR com a ferramenta Tesseract para extrair dados automaticamente de documentos oficiais, como CNHs digitais, com o objetivo de facilitar a emissão de certificados digitais. Embora o estudo não esteja diretamente relacionado à validação de certificados acadêmicos, ele evidencia a aplicabilidade do OCR em fluxos administrativos e documentais.

Ainda no contexto nacional, destaca-se o uso do Sistema Integrado de Gestão Acadêmica (SIGA), adotado pela Universidade Federal do Rio de Janeiro (UFRJ). O sistema possibilita o acesso remoto a dados acadêmicos e centraliza processos administrativos como matrículas, controle de notas e frequência. Apesar de sua contribuição à digitalização da gestão universitária, o SIGA ainda apresenta limitações importantes quanto à automação de etapas específicas, como a análise e validação de certificados acadêmicos, que continuam sendo realizadas manualmente pelos coordenadores (Hüller, Gomes e Santos, 2022).

No cenário internacional, destaca-se o sistema DocuExpert, uma plataforma comercial que aplica OCR e algoritmos de inteligência artificial para realizar a extração e verificação de documentos acadêmicos em larga escala, como certificados e históricos escolares (DocuExpert, 2025). A ferramenta é utilizada por instituições e conselhos educacionais estrangeiros, sendo voltada para contextos com alto volume de dados e necessidade de automação.

No Quadro 1, é realizado um comparativo dessas ferramentas e seus requisitos técnicos com o sistema proposto DocVerifier:

Quadro 1 – Comparativo dos trabalhos correlatos e do sistema proposto

Projeto	Sistema Web	OCR	IA/IAGen/RAG	Foco Documento	Validação Automática
UFSC (Alves, 2022)	Sim	Sim	Não	CNH Digital	Sim
SIGA – UFRJ (Hüller, Gomes e Santos, 2022)	Sim	Não	Não	Histórico Escolar, Matrícula, Notas	Não
DocuExpert (DocuExpert, 2025)	Sim	Não	Sim	Certificados e Históricos Acadêmicos	Sim
DocVerifier	Sim	Sim	Sim	Certificados de Atividades Complementares	Sim

Fonte: Elaborado pelos autores.

Conforme evidenciado, a solução apresentada se diferencia das demais ao integrar tecnologias de OCR e modelos baseados em inteligência artificial, incluindo técnicas de RAG, para automatizar a validação de certificados acadêmicos. Essa combinação proporciona uma contribuição significativa à gestão acadêmica e à qualidade dos procedimentos institucionais.

3 O QUE SERÁ FEITO

Para apresentação do TCC1, serão demonstrados o processo de extração de texto realizado pelo OCR e a geração do relatório executado pela LLM.


Quanto à parte do sistema, será demonstrado um website (DocVerifier) com as funções de cadastro de usuário, upload dos documentos e armazenamento de dados no banco, por meio dos endpoints GET, POST, DELETE e PUT. A publicação do sistema será feita na plataforma Render, que também será utilizada para automatizar os processos de integração e entrega contínua (CI/CD), facilitando o *deploy* e as atualizações do sistema durante o desenvolvimento.

Para a apresentação final, espera-se dar continuidade ao desenvolvimento do sistema, focando na integração das diferentes frentes, aprimorando a funcionalidade e garantindo a coerência entre os processos de extração, geração de relatórios e gerenciamento de dados. O escopo também contempla a implementação da tecnologia RAG, que permitirá aumentar a precisão e a contextualização das respostas geradas pela LLM, a partir da busca de informações relevantes em uma base de dados previamente estruturada.

Além disso, para validar a eficácia e funcionalidade do sistema, será realizado um processo de validação com usuários finais (coordenadores e alunos), por meio de questionários e da utilização prática do sistema.

A Figura 1 a seguir apresenta a arquitetura de alto nível do sistema DocVerifier, composta por três camadas: Camada de IA, Camada de Dados e Camada de Interface com o Usuário.

Figura 1 – Diagrama de arquitetura do sistema DocVerifier



Fonte: Elaborado pelos autores.

Na Camada de IA, é realizada a extração de texto dos documentos (OCR), organização das informações (Contexto), busca de dados relevantes (RAG) e geração de relatórios (LLM).

A Camada de Dados é responsável pelo armazenamento dos metadados no MongoDB, *embeddings* no Banco de Dados Vetorial, que são representações numéricas dos textos, utilizadas para buscas por similaridade semântica. Esse banco é essencial para o funcionamento do RAG e permite também integração com serviços externos via REST. Além disso, essa camada inclui a API desenvolvida em Flask, que atua como intermediária entre as camadas, gerenciando as requisições e coordenando o fluxo de dados do sistema.

Por fim, na Camada de Interface com o Usuário, ocorre a interação do usuário com o sistema, por meio de um *frontend* desenvolvido em Vue.js. O fluxo inicia com o envio do documento, passa pelo processamento e geração da resposta, e retorna as informações ao usuário.

A Figura 2 apresenta uma das telas do sistema DocVerifier, que tem como função a validação das atividades dos alunos pelo coordenador.

Figura 2 – Tela de Validação de Atividades do sistema DocVerifier

</ DocVerifier >

Gerar Relatório [Validar Atividades](#)

Bem-vindo Coordenador!

Andressa Braga Vieira Rodrigues - 210058 - Engenharia da Computação ▲

- Tipo de Atividade: Curso de Extensão
- Título: Python para Iniciantes
- Quantidade de Horas: 20 horas
- Data de Conclusão: 10/04/2024

✓ ✗

Diogo Vital Vieira - 211202 - Engenharia da Computação ▼

Pedro Henrique Lisboa - 210123 - Engenharia Mecatrônica ▼

Fonte: Elaborado pelos autores

Nesta, é possível visualizar o tipo de atividade, o título, a carga horária atribuída e a data de conclusão extraídos e filtrados pela IA, evitando casos de duplicidade ou falta de informações. Restando ao coordenador, apenas a etapa final de conferência e aprovação.

4 O QUE NÃO SERÁ FEITO

Não serão implementadas notificações por e-mail para alertas ou atualizações, nem será realizada a verificação da autenticidade das entidades emissoras dos documentos. Além disso, o foco será exclusivamente na construção de uma ferramenta funcional, sem a aplicação de medidas avançadas de segurança de dados, como criptografia adicional ou outras técnicas de proteção. Essas limitações visam otimizar o desenvolvimento e a integração das funcionalidades principais do sistema.

5 BENEFÍCIOS

Tendo em vista o contexto de validação de atividades complementares no âmbito acadêmico, buscou-se a criação de um sistema que facilite e automatize o processo atual utilizado nas instituições de ensino superior. Com a criação deste website, a Inteligência Artificial será responsável por verificar as informações, permitindo que o coordenador apenas as aprove, sem a necessidade de analisá-las manualmente. Isso otimiza o tempo e libera o profissional para se dedicar a outras atividades. Para os alunos, o sistema oferecerá uma interface intuitiva e um processo simplificado para o envio dos certificados. Além disso, permitirá o acompanhamento em tempo real do status de validação das atividades cadastradas, informando se foram aprovadas ou recusadas, assim como o motivo da recusa.

No aspecto técnico, a integração de técnicas de IA, incluindo OCR, modelos de linguagem e RAG, proporciona avanços nesse meio. A automação do processo de leitura, interpretação e validação dos certificados reduz a incidência de erros humanos, além de garantir precisão na extração e análise dos dados. Isso não apenas otimiza o fluxo de trabalho, mas também assegura maior confiabilidade nas informações processadas, contribuindo diretamente para a padronização, agilidade e qualidade dos procedimentos acadêmicos.

6 METAS PARA O TCC 2

As metas para o TCC2 para desenvolver o sistema de gestão de horas complementares são:

- Integração da camada de IA com as camadas de *backend* e *frontend*;
- Migração para banco de dados relacional, visando maior integridade transacional e consultas estruturadas;
- Implementar RAG com *vector-store* persistente e *endpoint* de busca semântica para o LLM;
- Pesquisa de validação com base em indicadores como taxa de certificados por minuto e repetição por ID;
- Finalizar a monografia e apresentação para a banca.

7 RECURSOS UTILIZADOS

Para desenvolvimento do projeto foi utilizado a IDE Visual Studio Code 2025, utilizando a linguagem de programação Python, em conjunto com bibliotecas comumente utilizadas para aplicações de LLM e de extrações de textos em arquivos (OpenAI, OCR, Tesseract) (Openai AI, 2025; Zelic e Sable, 2023). Devido à sua ampla adoção no mercado, essas ferramentas oferecem agilidade de desenvolvimento, manutenção simplificada e aderência aos requisitos de processamento de linguagem natural e extração de texto do projeto.

Para o desenvolvimento do *layout* do website, utilizou-se o Vue.js 3, por sua estrutura reativa e facilidade na criação de interfaces dinâmicas; TypeScript, que oferece maior segurança e organização no código; e o *framework* Vuetify 3, que disponibiliza componentes prontos e responsivos baseados no Material Design. Essa combinação proporcionou uma experiência de desenvolvimento mais ágil e uma interação mais fluida e agradável para o usuário. (Vue.js, 2025)

O *backend* foi desenvolvido utilizando a linguagem TypeScript, escolhida por sua tipagem estática que reduz erros e facilita a manutenção. A API se conecta a um banco de dados MongoDB, selecionado por sua flexibilidade no tratamento de dados não estruturados e integração com aplicações modernas. Para manipulação e visualização dos dados, foi utilizado o Prisma.io, que simplifica a criação de *queries* com segurança e agilidade. As requisições foram testadas com a extensão “Thunder Client”, prática e leve, integrada ao Visual Studio Code, facilitando o envio de dados em formato JSON. (TypeScript, 2025).

REFERÊNCIAS

ALVES, Arthur M. R. **Serviço de emissão de certificados digitais com base em dados de CNHs digitais**. 2022. Trabalho de Conclusão de Curso (Bacharelado em Sistemas de Informação) – Universidade Federal de Santa Catarina, Araranguá, 2022. Disponível em: <https://repositorio.ufsc.br/handle/123456789/243456>. Acesso em: 10 mai. 2025.

BERNADONI, Airton da Rocha. **Plataforma Web para o Gerenciamento de Atividades Acadêmicas Complementares de Cursos de Graduação**. 2023. Trabalho de Conclusão do Curso de Tecnologia em Sistemas Para Internet – Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Sul (IFRS), Porto Alegre, 2023. Disponível em: <https://repositorio.ifrs.edu.br/xmlui/bitstream/handle/123456789/980/123456789980.pdf?sequence=1&isAllowed=y>. Acesso em: 13 mar. 2025.

BEZERRA, Erich Teles *et al.* O IMPACTO DO USO DA INTELIGÊNCIA ARTIFICIAL NOS PROCESSOS DE ENSINO E APRENDIZAGEM. **Revista Ibero-Americana de Humanidades, Ciências e Educação**, [S. l.], v. 10, n. 7, p. 1211–1220, 2024. DOI: 10.51891/rease.v10i7.14859. Disponível em: <https://periodicorease.pro.br/rease/article/view/14859>. Acesso em: 16 mar. 2025.

BRASIL. Ministério da Educação. Resolução nº 5, de 16 de novembro de 2016. Brasília, DF, 2016. 9 p.

COOPER, Alan; REIMAN, Robert. **About Face 2.0: The Essentials of Interaction Design**. 2. ed. Indianapolis: Wiley, 2003.

DOCUEXPRT. **AI-Powered Document Reader and Verifier for Education**. 2025. Disponível em: <https://www.docuexpirt.com>. Acesso em: 12 maio 2025.

EADSIMPLES. **Automação educacional: o que é, como funciona e quais as vantagens?**. 2023. Disponível em: <https://www.eadsimples.com.br/educacao/automacao-educacional-o-que-e-como-funciona-e-quais-as-vantagens/>. Acesso em: 18 mar. 2025.

FACULDADE FASOUZA. **Tudo o que você precisa saber sobre horas complementares na faculdade**. 2024. Disponível em: <https://fasouza.com.br/fasouza/noticias/tudo-o-que-voce-precisa-saber-sobre-horas-complementares-na-faculdade>. Acesso em: 20 mar. 2025.

FRAUCHES, Celso. **Educação Superior Comentada: políticas, diretrizes, legislação e normas do ensino superior**. 2012. Disponível em: <https://abmes.org.br/colunas/detalhe/500/educacao-superior-comentada-politicas-diretrizes-legislacao-e-normas-do-ensino-superior>. Acesso em: 20 mar. 2025.

GAO, Yunfan *et al.* **Retrieval-Augmented Generation for Large Language Models: A Survey**, arXiv: 2312.10997. 2023. Disponível em: <https://arxiv.org/abs/2312.10997>. Acesso em: 31 mar.2025.

GARRETT, Jesse. **The Elements of User Experience: User-Centered Design for the Web and Beyond**. 2. ed. Berkeley: New Riders, 2010.

HÜLLER, Keylha Santana; GOMES, Jorge Henrique Coelho; SANTOS, Viviani Marques Leite dos. **Mapeamento de sistemas de gerenciamento de documentos acadêmicos e expedição de diploma digital em universidades**. Ciência da Informação, Brasília, v. 51, n. 3, p. 77–93, 2022. Disponível em: <https://revista.ibict.br/ciinf/article/view/5497>. Acesso em: 24 abr. 2025.

NISHIO, S. *et al.* **Extraction of Research Objectives, Machine Learning Model Names, and Dataset Names from Academic Papers and Analysis of Their Interrelationships Using LLM and Network Analysis**, arXiv: 2408.12097. 2024. Disponível em: <https://arxiv.org/pdf/2408.12097>. Acesso em: 20 mar. 2025.

NISSEN, Natalia. **Univates Digital automatiza a validação das atividades complementares para os cursos de graduação**. 2022. Disponível em: <https://www.univates.br/noticia/32170-univates-digital-automatiza-a-validacao-das-atividades-complementares-para-os-cursos-de-graduacao>. Acesso em: 22 mar. 2025.

OPENAI. **OpenAI Python API – API Reference**. 2025. Disponível em: <https://platform.openai.com/docs/api-reference/introduction>. Acesso em: 10 maio 2025.

TYPESCRIPT. **Introduction**. 2025. Disponível em: <https://www.typescriptlang.org/pt/>. Acesso em: 10 mai. 2025.

UNIVERSIDADE FEDERAL DE SANTA CATARINA. **Validação de atividades complementares**. 2022. Disponível em: <https://design.ufsc.br/validacao-de-atividades-complementares/>. Acesso em: 14 mar. 2025.

UNIVERSIDADE POTIGUAR. **Atividades complementares: o que são?** 2023. Disponível em: <https://www.unp.br/blog/atividades-complementares-o-que-sao>. Acesso em: 13 mar. 2025.

VUE.JS, **Introduction**, 2025. Disponível em: <https://vuejs.org/guide/introduction.html>. Acesso em: 18 mai. 2025.

XIAO, Tong; ZHU, Jingbo. **Foundations of Large Language Models**. Shenyang: Northeastern University, 2025. Disponível em: <https://arxiv.org/abs/2501.09223>. Acesso em: 20 mar. 2025.

ZELIC, Filip; SABLE, Anuj. **Python OCR Tutorial: Tesseract, Pytesseract, and OpenCV**. 2023. Disponível em: <https://nanonets.com/blog/ocr-with-tesseract/>. Acesso em: 10 mai. 2025.